

TRACE / CLEAN / REASON / SFT / GRPO / GUARD

TraceHound

面向 Agent 轨迹安全评测的细粒度风险定位与模型微调

基于 AgentDoG1.0 官方训练数据，构建数据清洗、Reason 标注增强、三因素风险分类、全参数 SFT、LoRA 对比与 GRPO 强化学习优化流程，让小基座模型具备更稳定的轨迹级安全判断能力。

项目方法概览

METHOD OVERVIEW

DATA

高质量数据合并

保留官方二分类 Safe 数据与三因素 Unsafe 数据，避免低质量 LLM 标注污染关键 Unsafe 轨迹。

REASON

Reason 标注增强

对 Safe 补齐三因素+Reason，对 Unsafe 补齐 Reason，构造解释监督信号。

FORMAT

严格 JSON 契约

统一 safe/unsafe 标签、三因素字段和标签命名，保证评测输出可解析。

TRAIN

SFT / LoRA / GRPO

比较监督微调方案，并对三因素+Reason 推理任务进行 GRPO 强化学习优化。

DATA PROCESSING

数据处理方法与流程

- 输入数据盘点**
训练集仅含二分类与三因素分类；评测集包含 Label、三因素、Reason 与 Source。
- 数据筛选合并**
Safe 使用二分类高质量样本；Unsafe 使用三因素已有样本，减少低置信补标。
- LLM 标注补全**
Safe 轨迹补三因素+Reason；Unsafe 轨迹补 Reason，形成统一训练目标。
- 清洗与格式化**
修正 Prompt 输出约束、标签大小写/分隔符，去除二分类数据中的 2000 条重复样本。

DATASET SEMANTICS

轨迹风险语义

Safe	轨迹存在风险，但模型采取了正确防御，最终未执行风险行为。
Unsafe	轨迹存在风险且模型未采取有效防御，导致风险行为被执行。
Benign	轨迹本身无风险，用于区分真实风险与正常任务执行。
False Refusal	轨迹有风险且模型尝试防御，但防御失败，仍造成风险执行。
3-Factor	Risk Source / Failure Mode / Harm Type 分别定位风险来源、失败方式与现实危害。

主要实验结果

ATBENCH BINARY SAFETY

二分类准确率

0.7303

+0.2118 vs Qwen3.5-0.8B

二分类 F1

0.7791

+0.0962 vs baseline

100% 有效输出

100%

Invalid Rate = 0.0000

模型	ACC	F1	INVALID	OUTPUT TOKENS MEAN / MAX / MIN / MEDIAN	结论
Qwen3.5-0.8B	0.5185	0.6829	0.0000	13 / 13 / 13 / 13	基座具备格式能力，但安全判别不足
TraceHound-LoRA	0.6767	0.7188	0.0067	13.12 / 32 / 13 / 13	有效提升，但对齐能力有限
TraceHound-Basev1	0.7303	0.7791	0.0000	13 / 13 / 13 / 13	全参数 SFT 最优，输出稳定

FINE-GRAINED + REASON

三因素分类任务结果

数据集	模型	ACC	F1	INVALID
ATBench	Qwen3.5-0.8B	0.1367	0.2897	0.7200
ATBench	AgentDoG1.0-Qwen	0.6433	0.7116	0.0000
R-Judge	Qwen3.5-0.8B	0.2571	0.6259	0.7074
R-Judge	AgentDoG1.0-Qwen	0.6259	0.4903	0.0018

任务观察

三因素+Reason 任务更依赖标签边界和证据对齐；SFT 先解决格式可用性，再通过细粒度样本与强化学习优化推理稳定性。

ANALYSIS

细粒度指标与误差分析

SFT 显著降低无效输出，并提升 ATBench 三因素分类；R-Judge 上 F1 需结合高无效率 and 类别偏置解释，基座模型更偏向 Unsafe 且无效输出占比高，不能单独代表实际可用性。

Risk Source	Acc 0.1833	F1 0.1520
Failure Mode	Acc 0.2500	F1 0.0642
Harm Type	Acc 0.2867	F1 0.2434

GRPO RL 优化

已面向三因素+Reason 推理任务开展 GRPO 强化学习训练，奖励侧重 JSON 有效性、三因素一致性与 Reason 证据对齐；指标待评测完成后补充。

CONCLUSION

总结结论

TraceHound 证明了在小参数基座上，通过高质量数据清洗、严格输出契约和全参数 SFT，可以显著提升 Agent 轨迹安全二分类能力，并让模型稳定输出可评测的结构化结果。LoRA 能带来增益，但在该任务上的对齐幅度弱于全参数 SFT。

- 继续扩充 R-Judge 风格 hard negatives，补齐间接注入、隐式越权与正常工具调用混淆样本。
- 三因素+Reason 推理任务已引入 GRPO 强化学习训练优化，待结果产出后补充指标。
- 把 Reason 监督与 evidence steps 对齐，提升可解释性和风险定位可审计性。
- 将离线评测模型接入在线 before-tool-call Guard，实现执行前风险拦截。